

Generative Models 1

- **Generation (sampling)**

확률분포 $p(x)$ 와 유사한 어떤 새로운 x_{new} 를 만들어서, 유사 이미지 만들어냄.

- $x_{new} \sim p(x)$

- **Density estimation (anomaly detection)**

어떤 이미지 x 가 맞는지 아닌지 판별

$p(x)$ 높으면 맞음 / 낮으면 아님

- Discriminator 모델 포함, 어떤 이미지가 특정 레이블에 속하는지 아닌지 판단

- implicit model(암시적 모델): VAE, GAN처럼 생성만 하는 모델 (Generation만 함)
 - explicit model(명시적 모델): 확률값까지도 얻어낼 수 있는 모델 (Discriminator 포함)

- **Unsupervised representation learning (feature learning)**

이미지의 공통적 특징(feature) 학습

- **Basic Discrete Distributions**

- **Bernoulli distribution**(베르누이 분포): (biased) coin flip (1,0)

$$D = \{\text{Heads}, \text{Tails}\}$$

앞면 나올 확률: $P(X = \text{Heads}) = p$, 뒷면 나올 확률: $P(X = \text{tails}) = 1 - p$

$$X \sim \text{Ber}(p) \text{로 표현}$$

파라미터 1개 (p 하나)

- **Categorical distribution**(카테고리 분포): (biased) m-sided dice

$$D = \{1, \dots, m\}$$

주사위 던져 i 가 나올 확률: $P(Y = i) = p_i, \sum_{i=1}^m p_i = 1$

$$Y \sim \text{Cat}(p_1, \dots, p_m) \text{로 표현}$$

파라미터 $m - 1$ 개

- RGB 픽셀 하나, Joint distribution(결합분포) 모델링

$$(r, g, b) \sim p(R, G, B)$$

가능한 색상 종류(경우의 수): $256 \times 256 \times 256$ 개

필요한 파라미터의 개수: $255 \times 255 \times 255$ 개

=> 파라미터 숫자 많음

- n 개의 binary pixels(1개의 binary image) X_1, \dots, X_n

가능한 경우의 수: $2 \times \dots \times 2 = 2^n$ 개

필요한 파라미터의 개수: $2^n - 1$ 개

=> 파라미터 많이 필요

- **Structure Through Independence**

모든 픽셀 X_1, \dots, X_n 가 각각 독립적이라고 가정(**independence assumption**)

$$p(x_1, \dots, x_n) = p(x_1)p(x_2)\dots p(x_n)$$

가능한 경우의 수: 2^n 개

$p(x_1, \dots, x_n)$ 을 구하기 위해 필요한 파라미터 개수: n 개

똑같이 2^n 개의 경우의 수 나타내지만, 파라미터 n 개만 필요

- **Conditional Independence**

기존 Fully Dependant 모델링과 Independent 모델링의 중간점으로 타협

- **Chain rule**

$$p(x_1, \dots, x_n) = p(x_1)p(x_2|x_1)p(x_3|x_1, x_2) \dots p(x_n|x_1, \dots, x_{n-1})$$

- **Bayes' rule**

$$p(x|y) = \frac{p(x,y)}{p(y)} = \frac{p(y|x)p(x)}{p(y)}$$

- **Conditional independence**

If $x \perp y|z$, then $p(x|y, z) = p(x|z)$

- Markov assumption 적용 시, 획기적으로 감소

- **parameters**

- **Chain rule 이용 시,**

$$p(x_1, \dots, x_n) = p(x_1)p(x_2|x_1)p(x_3|x_1, x_2) \dots p(x_n|x_1, \dots, x_{n-1})$$

- 파라미터 개수

$p(x_1)$: 1개

$p(x_2|x_1)$: 2개 $\Rightarrow p(x_2|x_1 = 0), p(x_2|x_1 = 1)$

$p(x_3|x_1, x_2)$: 4개

total: $1 + 2 + 2^2 + \dots + 2^{n-1} = 2^n - 1$ 개

\Rightarrow fully dependant 모델과 같음

n 개의 independent binary pixel 가진 이미지의 파라미터 수로도 해석 가능

- **Markov assumption** 적용 시, 획기적으로 감소

X_{i+1} 는 X_i 에만 dependant, X_1, \dots, X_{i-1} 까지는 independent으로 가정

$X_{i+1} \perp X_1, \dots, X_{i-1} | X_i$

$$p(x_1, \dots, x_n) = p(x_1)p(x_2|x_1)p(x_3|x_2) \dots p(x_n|x_{n-1})$$

- 파라미터 개수: $2n - 1$ 개

\Rightarrow 파라미터 개수 지수 차원에서 끌어내릴 수 있음

- **Auto-regressive Model, AR모델, 자기회귀모델**

하나의 정보가 이전의 정보에 dependant한 것

Markov assumption처럼 직전 정보에만 dependant한 것 & x_1, \dots, x_{i-1} 까지 모두 dependant한 것

Markov chain 활용 \Rightarrow 이전의 n 개(AR- n model) / 1개(AR-1 model) 고려

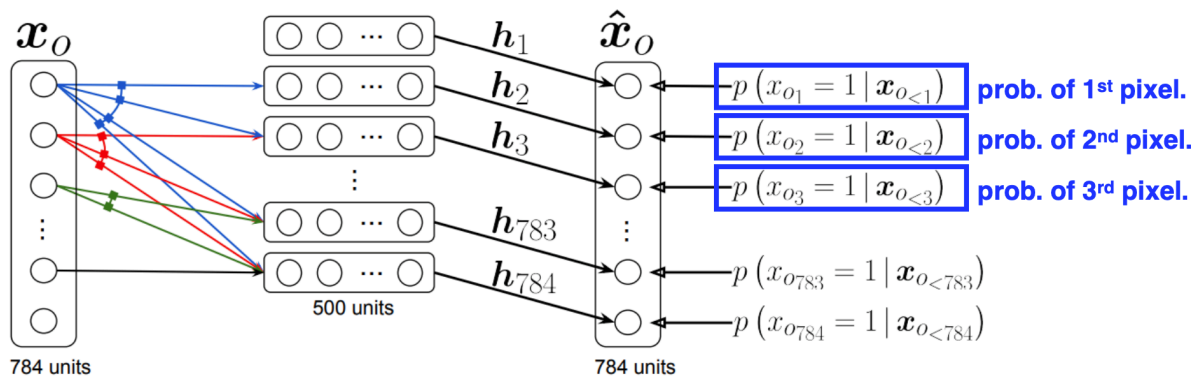
chain rule로 joint distribution 나눔

랜덤 변수들의 순서(order) 필요

- 이미지(2차원)의 순서(1차원)을 어떻게 매기느냐 \Rightarrow 성능 달라짐

○ 어떤 식으로 conditional independence 주는가 => 전체 모델의 structure 달라짐

• NADE(Neural Autoregressive Density Estimator)



$$p(x_i | x_{1:i-1}) = \sigma(\alpha_i h_i) \text{ where } h_i = \sigma(W_{<i x_{1:i-1}} + c)$$

i 번째 픽셀을 1, 2, ..., i 번째 픽셀까지에 dependent

매번 뉴럴넷 층으로 보냄 => 층의 사이즈 점차 커짐 => **weight 길이 가변적**

explicit model로, generation뿐만 아니라 **확률(density) 계산 가능**

$$p(x_1, \dots, x_{784}) = p(x_1)p(x_2|x_1) \dots p(x_{784}|x_{1:783})$$

○ joint dist 이용해 $p(x_i | x_{1:i-1})$ 계산, 전체 확률 알 수 있음

=> 해당 이미지 판별: **discriminator** 역할 수행 가능

continuous variables(임의의 연속변수) 모델링 경우, 마지막 layer에 gaussian mixture model(가우시안 혼합) 활용, 연속 dist 생성 가능

• Pixel RNN

AR 모델을 만들기 위해 RNN 활용

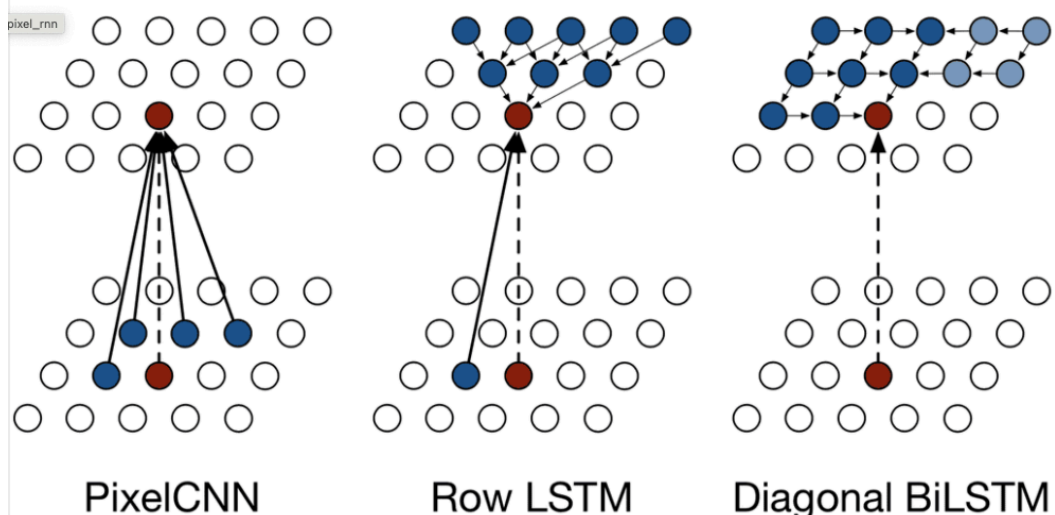
$$p(x) = \prod_{i=1}^{n^2} (\text{prob } i\text{번째 R}) (\text{prob } i\text{번째 G}) (\text{prob } i\text{번째 B})$$

$$p(x) = \prod_{i=1}^{n^2} p(x_{i,R} | x_{<i}) p(x_{i,G} | x_{<i}, x_{i,R}) p(x_{i,B} | x_{<i}, x_{i,R}, x_{i,G})$$

기존 모델: AR 모델을 **전열결계층(dense layer)** 가진 신경망

Pixel RNN: **RNN** 이용

○ ordering 따른 종류



- **Row LSTM**

i 번째 픽셀을 만들 때, 위쪽 row와 바로 직전 픽셀 활용

- **Diagonal BiLSTM**

i 번째 픽셀을 만들 때 이전의 모든 픽셀 활용